KI Fachblatt

KI-Tagesbericht

Dienstag, 20.10.2026 · Trending-Modelle und die Analysen des Tages

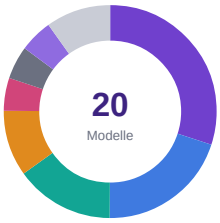
Modelle im Ranking	Downloads gesamt	Höchster Trend-Score	Jüngstes Modell
20	**15,6 Mio.**	**1.594**	**vor 3 Tg.**
Top-Auswahl der HF-API	Zähler der API, kein Qualitätsmaß	DeepSeek-V4.1-Flash-1017	DeepSeek-V4.1-Flash-1017

Trend-Ranking

Top 10 nach Trend-Score · Stand 20.10.2026, 09:22 Uhr

1	DE	**DeepSeek-V4.1-Flash-1017** deepseek-ai · Bild+Text zu Text	1.594
2	BL	**flux-3-image-klein-comfy** black-forest-labs · Bild zu Bild	773
3	FI	**drama-3** fishaudio · Sprachsynthese	754
4	OP	**MiniCPM-V-4.7-35B-A3B** openbmb · Bild+Text zu Text	693
5	Google DeepMind	**embeddinggemma-2** google · Embeddings	597
6	JI	**humanizer** jialinyyzz · Textgenerierung	577
7	Meta	**Muse-Spark-Open-816B-A42B** meta-models · Bild+Text zu Text	538
8	LI	**LFM2.5-24B-A2B** LiquidAI · Textgenerierung	488
9	BL	**flux-3-image-klein** black-forest-labs · Bild zu Bild	484
10	LI	**LTX-2.5** Lightricks · Bild zu Video	438

Aufgaben im Ranking



Bild+Text zu Text	6
Text zu Bild	4
Textgenerierung	3
Bild zu Bild	2
Sprachsynthese	1
Embeddings	1
Bild zu Video	1
Weitere	2

Alter der Modelle



bis 7 Tage	5
8 bis 30 Tage	9
31 bis 180 Tage	6
älter	0

Wer vorn liegt

BL	**black-forest-labs**	2
OP	**OpenMOSS-Team**	2
QW	**Qwen**	2
DE	**deepseek-ai**	1
FI	**fishaudio**	1

Beachtung und Nutzung

Likes gegen Downloads, logarithmisch



Jeder Punkt ist ein Modell, die Größe zeigt den Trend-Score. Hohe Downloads bei wenigen Likes und umgekehrt sind normal und sagen nichts über Qualität.

Alle 20 Modelle

Top 20 laut Hugging-Face-API · Stand 20.10.2026, 09:22 Uhr

#	MODELL	AUFGABE	LIKES	DOWNLOADS	TREND-SCORE	ERSTELLT
1	DeepSeek-V4.1-Flash-1017 deepseek-ai	Bild+Text zu Text	1.760	17.924	1.594	2026-10-17
2	flux-3-image-klein-comfy black-forest-labs	Bild zu Bild	1.004	393.062	773	2026-10-14
3	drama-3 fishaudio	Sprachsynthese	787	11.795	754	2026-10-01
4	MiniCPM-V-4.7-35B-A3B openbmb	Bild+Text zu Text	1.072	76.410	693	2026-10-07
5	embeddinggemma-2 google	Embeddings	2.734	167.750	597	2026-09-14
6	humanizer jialinyyzz	Textgenerierung	2.001	109.937	577	2026-09-11
7	Muse-Spark-Open-816B-A42B meta-models	Bild+Text zu Text	587	2.109	538	2026-09-15
8	LFM2.5-24B-A2B LiquidAI	Textgenerierung	504	14.151	488	2026-10-12
9	flux-3-image-klein black-forest-labs	Bild zu Bild	534	62.006	484	2026-10-13
10	LTX-2.5 Lightricks	Bild zu Video	8.516	2.019.834	438	2026-07-23
11	MOSS-Image-SFT OpenMOSS-Team	Text zu Bild	448	3.336	425	2026-10-11
12	MOSS-Image-Base OpenMOSS-Team	Text zu Bild	394	2.774	375	2026-10-11
13	Qwen-Image-2.1-Uncensored-Quantized abenzerps	Text zu Bild	4.656	2.739.572	371	2026-09-20
14	Qwen3.8-27B Qwen	Bild+Text zu Text	18.025	7.458.401	289	2026-08-05
15	Unlimited-OCR baidu	Bild+Text zu Text	4.827	1.799.825	251	2026-06-19
16	indra-ocr datalab-to	Bild zu Text	250	2.433	246	2026-10-10
17	MOSS-Image Comfy-Org	Ohne Angabe	250	673.110	244	2026-10-16
18	Qwen3.8-Flash-Next-FP4-Local nvidia	Bild+Text zu Text	242	6.047	238	2026-10-08
19	Qwen-Image-2.1-Turbo Qwen	Text zu Bild	1.001	25.033	235	2026-10-09
20	Hy-Memory-30B-A3B tencent	Textgenerierung	223	1.571	220	2026-10-15

So lesen: Reihenfolge nach dem Feld *trendingScore* der Hugging-Face-API, Stand 20.10.2026, 09:22 Uhr. Likes, Downloads und Trend-Score sind Zähler der API, keine Qualitätsbewertung und kein Benchmark-Ergebnis. Die Diagramme zeigen nur diese Zähler.

Aus dem KI-Verzeichnis

Modelle mit Quellen auf kifachblatt.de/ki-modelle

GPT-6 Astra

OpenAI

GPT-6 Astra ist ein OpenAI-Modell für komplexes Reasoning, Programmieren, Recherche und Dokumentarbeit.

Ein Text Bild → Aus Text

Claude Opus 5

Anthropic

Claude-Modell für komplexe Programmier- und Unternehmensaufgaben.

Ein Text Bild → Aus Text

Claude Sonnet 5

Anthropic

Claude-Modell, das laut Anbieter Geschwindigkeit und Leistungsfähigkeit verbindet.

Ein Text Bild → Aus Text

Gemini 4 Argon

Google DeepMind

Multimodales Reasoning-Modell für komplexe technische und berufliche Aufgaben.

Ein Text Bild Audio Video → Aus Text

13. Oktober 2026

Mistral Small 4

Mistral AI

Ein hybrides Modell für Anweisungen, Reasoning und Programmieren.

16. März 2026

Mistral Large 3

Mistral AI

Ein multimodales Open-Weight-Modell mit Mixture-of-Experts-Architektur.

2. Dezember 2025

Nemotron 3.5 Super VL NVFP4

NVIDIA

Ein Modell für Text, Bilder und Video mit quantisierten Gewichten.

Ein Text Bild Video → Aus Text

15. Oktober 2026

Muse Spark

Meta

Multimodales Reasoning-Modell, das Meta AI antreibt.

8. April 2026

Benchmark-Angaben der Hersteller

GPQA Diamond · Nemotron 3.5 Super VL NVFP4

89,90 %

Herstellertabelle, laut NVIDIA

SWE-bench Verified Verified · Nemotron 3.5 Super VL NVFP4

71,07 %

Herstellertabelle, laut NVIDIA

Terminal-Bench 2.1 2.1 · Nemotron 3.5 Super VL NVFP4

60,80 %

Herstellertabelle, laut NVIDIA

SWE-bench Verified Verified · MiniMax-M2.1

74,00 %

Herstellertabelle, laut MiniMax

MMLU-Pro - · MiniMax-M2.1

88,00 %

Herstellertabelle, laut MiniMax

GPQA Diamond · MiniMax-M2.1

83,00 %

Herstellertabelle, laut MiniMax

SWE-bench Verified Verified · MiniMax-M2.5

80,20 %

Herstellertabelle, laut MiniMax

Einordnen: Diese Werte sind Herstellerangaben aus einer Modellkarte. Setup, Prompt und Budget sind nicht vollständig angegeben, die Zahlen eignen sich nicht für Ranglisten oder den Vergleich zwischen Modellen.

Quellen und Prüfdatum (2026-10-20) je Eintrag unter kifachblatt.de/ki-modelle und kifachblatt.de/benchmarks.

Die zwei Analysen des Tages

GRUNDLAGEN · 20.10.2026 · 10 QUELLEN

Quantisierung von Sprachmodellen: Verfahren, Zahlen, Grenzen

Wie viel Speicher 4 Bit pro Gewicht wirklich sparen, welche Verfahren von LLM.int8() bis BitNet b1.58 was taugen und wo die Grenzen liegen.

- 4-Bit-Quantisierung halbiert nicht nur, sie viertelt den Speicher der Gewichte: Ein 70-Milliarden-Parameter-Modell schrumpft von 140 auf 35 GB (eigene Rechnung).
- LLM.int8() zeigte 2022, dass 175-Milliarden-Modelle verlustfrei in 8 Bit laufen, wenn man wenige Outlier-Kanäle in 16 Bit auslagert.
- GPTQ, AWQ und SpQR machen 3 bis 4 Bit praxistauglich; QuaRot drückt Gewichte, Aktivierungen und KV-Cache gemeinsam auf 4 Bit, AQLM erreicht 2 Bit.

https://kifachblatt.de/llm-quantisierung-verfahren-grundlagen

Quellen

1. LLM.int8(): 8-bit Matrix Multiplication for Transformers at Scale (arxiv.org)
2. GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers (arxiv.org)
3. SmoothQuant: Accurate and Efficient Post-Training Quantization for Large Language Models (arxiv.org)
4. QLoRA: Efficient Finetuning of Quantized LLMs (arxiv.org)
5. AWQ: Activation-aware Weight Quantization for LLM Compression and Acceleration (arxiv.org)
6. SpQR: A Sparse-Quantized Representation for Near-Lossless LLM Weight Compression (arxiv.org)
7. Extreme Compression of Large Language Models via Additive Quantization (AQLM) (arxiv.org)
8. QuaRot: Outlier-Free 4-Bit Inference in Rotated LLMs (arxiv.org)
9. The Era of 1-bit LLMs: All Large Language Models are in 1.58 Bits (BitNet b1.58) (arxiv.org)
10. GGUF (Dokumentation) (huggingface.co)

MODELLE · 20.10.2026 · 6 QUELLEN

MiniMax M3.1 Flash: Agenten-Modell im Kosten- und Benchmark-Check

MiniMax verspricht fast dreifache Inferenzgeschwindigkeit und 70 Prozent weniger Kosten. Wir ordnen Benchmarks, Preise und das Space-Bunny-Vorspiel ein.

- MiniMax M3.1 Flash ist seit dem 19. Oktober 2026 über API, M Plan und MiniMax Code verfügbar; die Gewichte sollen später folgen.
- Herstellerangaben: 73,7 Prozent auf DeepSWE v1.1, 61,7 auf OSWorld V2, 82 Prozent auf CyberGym, Spitzen über 200 Ausgabetokens pro Sekunde.
- Der Preis liegt bei 0,15 Dollar pro Million Eingabetokens und 0,60 pro Million Ausgabetokens; MiniMax spricht von 70 Prozent weniger Kosten als beim Vorgänger.

https://kifachblatt.de/minimax-m3-1-flash-analyse

Quellen

1. MiniMax M3.1 Flash: Redefining Agent Performance and Cost (minimax.io)
2. MiniMax launches M3.1 Flash model, says it cuts AI agent costs by 70% (siliconangle.com)
3. MiniMax M3.1 Flash (blog.anyrouter.dev)
4. MiniMax M3.1 Flash now available on AI Gateway for free (vercel.com)
5. deepseek-ai/DeepSeek-V4.1-Flash (Modellkarte) (huggingface.co)
6. AI Model Releases in October 2026 (modeldrops.com)

Vollständige Texte mit Quellen, Methode und Grenzen auf kifachblatt.de. „Eigene Rechnung“ kennzeichnet Berechnungen der Redaktion auf Basis der genannten Quellen.

Impressum & Redaktionsschluss

Anbieter nach § 5 DDG

Philipp Paulik
Mozartstraße 1
53819 Neunkirchen-Seelscheid
Nordrhein-Westfalen

Verantwortlich nach § 18 Abs. 2 MStV

Philipp Paulik, Anschrift wie links

Redaktion

KI Fachblatt, Redaktion Philipp Paulik

Kontakt

E-Mail: philipp.l.paulik@gmail.com
Web: kifachblatt.de

Redaktionsschluss

Diese Ausgabe wurde am 20.10.2026, 09:22 Uhr automatisch erstellt. Später veröffentlichte Beiträge und Zählerstände sind nicht berücksichtigt.

Hinweis zu KI

Die Inhalte des KI Fachblatts werden mit Unterstützung von KI erstellt und redaktionell geprüft (siehe kifachblatt.de/transparenz). Dieser Bericht wird automatisch aus öffentlichen Daten und den veröffentlichten Beiträgen zusammengestellt. Trotz Prüfung können Fehler nicht ausgeschlossen werden.

Datenquellen

Modellliste: Hugging Face, öffentliche API (huggingface.co/api/models, Sortierung trendingScore), Stand 20.10.2026, 09:22 Uhr. Analysen und KI-Verzeichnis: eigene Beiträge und Quellenprüfung des KI Fachblatts. Diagramme: eigene Darstellung der API-Zähler. Logos nur aus dem lokalen, quellengeprüften Bestand des KI Fachblatts (siehe Logos und Marken), sonst Kürzel; keine Profilbilder von Hugging Face.

Logos und Marken

Logos stammen aus dem lokalen Bestand des KI Fachblatts (content/portrait-logos), unverändert und eingebettet, mit Quelle und Rechtehinweis je Datei. Marken gehören ihren jeweiligen Inhabern. Die Logos dienen der redaktionellen Identifikation und deuten keine Partnerschaft, Freigabe oder Empfehlung durch die Markeninhaber an. Wo kein eindeutig zugeordnetes Logo vorliegt, steht ein Kürzel. Modelllogos und Unternehmenslogos werden nicht vermischt.

- **claude**: https://commons.wikimedia.org/wiki/File:Claude_AI_logo.svg · PD-textlogo laut Commons; Markenrechte bleiben bestehen
- **gemini**: https://commons.wikimedia.org/wiki/File:Google_Gemini_logo_2025.svg · PD-textlogo laut Commons; Markenrechte bleiben bestehen
- **google-deepmind**: https://commons.wikimedia.org/wiki/File:Google_DeepMind_logo.png · PD-textlogo laut Commons; Markenrechte bleiben bestehen
- **meta**: https://commons.wikimedia.org/wiki/File:Meta_Platforms_Inc._logo.svg · PD-textlogo laut Commons; Markenrechte bleiben bestehen
- **mistral-large**: https://mistral.ai/brand/ · Offizielle Brand-Guidelines, keine freie Lizenz
- **mistral-small**: https://mistral.ai/brand/ · Offizielle Brand-Guidelines, keine freie Lizenz
- **nvidia**: https://commons.wikimedia.org/wiki/File:NVIDIA_logo.svg · Apache-2.0; Copyright NVIDIA Corporation. Lizenzdatei beigelegt.

© 2026 KI Fachblatt · Philipp Paulik · Stand 20.10.2026, 09:22 Uhr