KI Fachblatt

KI-Tagesbericht

Mittwoch, 21.10.2026 · Trending-Modelle und die Analysen des Tages

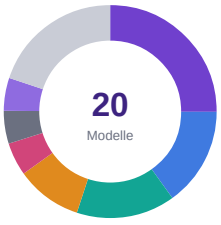
Modelle im Ranking	Downloads gesamt	Höchster Trend-Score	Jüngstes Modell
20	**18,1 Mio.**	**1.795**	**vor 4 Tg.**
Top-Auswahl der HF-API	Zähler der API, kein Qualitätsmaß	DeepSeek-V4.1-Flash-1017	DeepSeek-V4.1-Flash-1017

Trend-Ranking

Top 10 nach Trend-Score · Stand 21.10.2026, 08:10 Uhr

1	DE	**DeepSeek-V4.1-Flash-1017** deepseek-ai · Bild+Text zu Text	1.795
2	BL	**flux-3-image-klein-comfy** black-forest-labs · Bild zu Bild	837
3	FI	**drama-3** fishaudio · Sprachsynthese	655
4	Meta	**Muse-Spark-Open-816B-A42B** meta-models · Bild+Text zu Text	556
5	BL	**flux-3-image-klein** black-forest-labs · Bild zu Bild	511
6	Google DeepMind	**embeddinggemma-2** google · Embeddings	507
7	OP	**MOSS-Image-SFT** OpenMOSS-Team · Text zu Bild	472
8	LI	**LTX-2.5** Lightricks · Bild zu Video	436
9	JI	**humanizer** jialinyyzz · Textgenerierung	427
10	OP	**MOSS-Image-Base** OpenMOSS-Team · Text zu Bild	415

Aufgaben im Ranking



Bild+Text zu Text	5
Text zu Bild	3
Textgenerierung	3
Bild zu Bild	2
Sprachsynthese	1
Embeddings	1
Bild zu Video	1
Weitere	4

Alter der Modelle



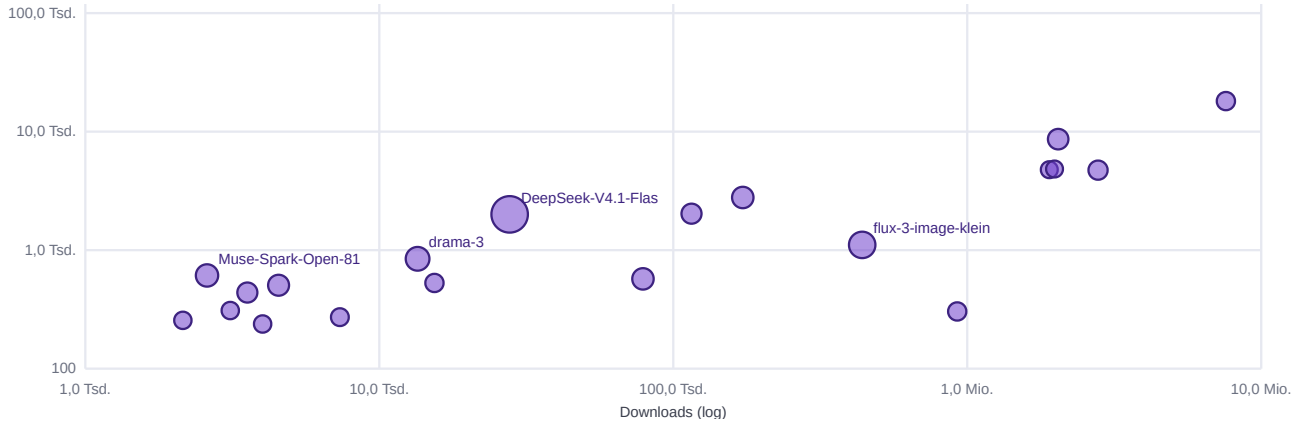
bis 7 Tage	6
8 bis 30 Tage	7
31 bis 180 Tage	6
älter	1

Wer vorn liegt

BL	**black-forest-labs**	2
OP	**OpenMOSS-Team**	2
DE	**deepseek-ai**	1
FI	**fishaudio**	1
Meta	**meta-models**	1

Beachtung und Nutzung

Likes gegen Downloads, logarithmisch



Jeder Punkt ist ein Modell, die Größe zeigt den Trend-Score. Hohe Downloads bei wenigen Likes und umgekehrt sind normal und sagen nichts über Qualität.

Alle 20 Modelle

Top 20 laut Hugging-Face-API · Stand 21.10.2026, 08:10 Uhr

#	MODELL	AUFGABE	LIKES	DOWNLOADS	TREND-SCORE	ERSTELLT
1	DeepSeek-V4.1-Flash-1017 deepseek-ai	Bild+Text zu Text	2.007	27.737	1.795	2026-10-17
2	flux-3-image-klein-comfy black-forest-labs	Bild zu Bild	1.108	439.528	837	2026-10-14
3	drama-3 fishaudio	Sprachsynthese	846	13.495	655	2026-10-01
4	Muse-Spark-Open-816B-A42B meta-models Meta	Bild+Text zu Text	613	2.592	556	2026-09-15
5	flux-3-image-klein black-forest-labs	Bild zu Bild	573	78.897	511	2026-10-13
6	embeddinggemma-2 google	Embeddings	2.776	172.474	507	2026-09-14
7	MOSS-Image-SFT OpenMOSS-Team	Text zu Bild	506	4.547	472	2026-10-11
8	LTX-2.5 Lightricks	Bild zu Video	8.648	2.039.447	436	2026-07-23
9	humanizer jialinyyzz	Textgenerierung	2.029	115.341	427	2026-09-11
10	MOSS-Image-Base OpenMOSS-Team	Text zu Bild	439	3.558	415	2026-10-11
11	Qwen-Image-2.1-Uncensored-Quantized abenzerps	Text zu Bild	4.726	2.788.283	350	2026-09-20
12	LFM2.5-24B-A2B LiquidAI	Textgenerierung	528	15.410	301	2026-10-12
13	Qwen3.8-27B Qwen	Bild+Text zu Text	18.081	7.586.857	291	2026-08-05
14	MOSS-Image Comfy-Org	Ohne Angabe	304	924.574	291	2026-10-16
15	Qwen3.8-Flash-Next-FP4-Local nvidia NVIDIA	Bild+Text zu Text	272	7.345	266	2026-10-08
16	indra-ocr datalab-to	Bild zu Text	309	3.111	253	2026-10-10
17	Hy-Memory-30B-A3B tencent	Textgenerierung	256	2.145	251	2026-10-15
18	Timestral-209M mistralai Mistral	time-series-forecasting	238	4.008	229	2026-10-14
19	sam3 facebook Meta	mask-generation	4.783	1.902.047	208	2025-11-07
20	Unlimited-OCR baidu	Bild+Text zu Text	4.845	1.981.704	198	2026-06-19

So lesen: Reihenfolge nach dem Feld *trendingScore* der Hugging-Face-API, Stand 21.10.2026, 08:10 Uhr. Likes, Downloads und Trend-Score sind Zähler der API, keine Qualitätsbewertung und kein Benchmark-Ergebnis. Die Diagramme zeigen nur diese Zähler.

Aus dem KI-Verzeichnis

Modelle mit Quellen auf kifachblatt.de/ki-modelle

GPT-6 Astra

OpenAI

GPT-6 Astra ist ein OpenAI-Modell für komplexes Reasoning, Programmieren, Recherche und Dokumentarbeit.

Ein Text Bild → Aus Text

Claude Opus 5

Anthropic

Claude-Modell für komplexe Programmier- und Unternehmensaufgaben.

Ein Text Bild → Aus Text

Claude Sonnet 5

Anthropic

Claude-Modell, das laut Anbieter Geschwindigkeit und Leistungsfähigkeit verbindet.

Ein Text Bild → Aus Text

Gemini 4 Argon

Google DeepMind

Multimodales Reasoning-Modell für komplexe technische und berufliche Aufgaben.

Ein Text Bild Audio Video → Aus Text

13. Oktober 2026

Mistral Small 4

Mistral AI

Ein hybrides Modell für Anweisungen, Reasoning und Programmieren.

16. März 2026

Mistral Large 3

Mistral AI

Ein multimodales Open-Weight-Modell mit Mixture-of-Experts-Architektur.

2. Dezember 2025

Nemotron 3.5 Super VL NVFP4

NVIDIA

Ein Modell für Text, Bilder und Video mit quantisierten Gewichten.

Ein Text Bild Video → Aus Text

15. Oktober 2026

Muse Spark

Meta

Multimodales Reasoning-Modell, das Meta AI antreibt.

8. April 2026

Benchmark-Angaben der Hersteller

GPQA Diamond · Nemotron 3.5 Super VL NVFP4

89,90 %



Herstellertabelle, laut NVIDIA

SWE-bench Verified Verified · Nemotron 3.5 Super VL NVFP4

71,07 %



Herstellertabelle, laut NVIDIA

Terminal-Bench 2.1 2.1 · Nemotron 3.5 Super VL NVFP4

60,80 %



Herstellertabelle, laut NVIDIA

SWE-bench Verified Verified · MiniMax-M2.1

74,00 %



Herstellertabelle, laut MiniMax

MMLU-Pro - · MiniMax-M2.1

88,00 %



Herstellertabelle, laut MiniMax

GPQA Diamond · MiniMax-M2.1

83,00 %



Herstellertabelle, laut MiniMax

SWE-bench Verified Verified · MiniMax-M2.5

80,20 %

Herstellertabelle, laut MiniMax

Einordnen: Diese Werte sind Herstellerangaben aus einer Modellkarte. Setup, Prompt und Budget sind nicht vollständig angegeben, die Zahlen eignen sich nicht für Ranglisten oder den Vergleich zwischen Modellen.

Quellen und Prüfdatum (2026-10-20) je Eintrag unter kifachblatt.de/ki-modelle und kifachblatt.de/benchmarks.

Die zwei Analysen des Tages

ARCHITEKTUR · 21.10.2026 · 7 QUELLEN

KV-Cache: Der stille Kostentreiber hinter langen KI-Kontexten

Eine Million Token Kontext klingt gratis, ist es aber nicht: Der KV-Cache frisst Speicher und Geld. Wie DeepSeek, Mistral und vLLM ihn drücken, mit Zahlen.

- DeepSeek drückt den globalen KV-Cache laut Modellkarte auf 890 Byte pro Token; das ist etwa ein Viertel von V4-Flash und rund 1/437 der ersten Generation.
- Der Cache wächst linear mit der Kontextlänge. Bei einer Million Token entscheidet seine Größe, wie viele Konversationen auf einer GPU Platz finden (eigene Rechnung).
- Die Gegenmittel im Überblick: geteilte Schlüsselköpfe (GQA), Kompression (MLA), Gleitfenster (SWA), Speicherverwaltung (PagedAttention) und Architekturen ganz ohne Cache (Mamba).

https://kifachblatt.de/kv-cache-kompression-deepseek-analyse

Quellen

1. DeepSeek-V4.1-Flash: Pushing the Limits of KV Cache Compression (Modellkarte) (huggingface.co)
2. DeepSeek-V4-Pro (Modellkarte der V4-Serie) (huggingface.co)
3. DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model (arxiv.org)
4. GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints (Ainslie et al.) (arxiv.org)
5. Mistral 7B (Jiang et al.) (arxiv.org)
6. Efficient Memory Management for Large Language Model Serving with PagedAttention (Kwon et al.) (arxiv.org)
7. Mamba: Linear-Time Sequence Modeling with Selective State Spaces (Gu & Dao) (arxiv.org)

GRUNDLAGEN · 20.10.2026 · 5 QUELLEN

Inferenz und Kosten verstehen: Tokens, KV-Cache, Quantisierung

Was beim Antworten passiert, warum der KV-Cache so viel Speicher frisst und woraus sich ein API-Preis ergibt, mit eigenen Rechnungen zu Llama 3.

- Ein Modell antwortet in zwei Phasen: Die Eingabe wird parallel verarbeitet, die Ausgabe Token für Token; die zweite Phase ist speicherlastig.
- Der KV-Cache kostet beim 13-Milliarden-Modell OPT 800 KB pro Token und bis zu 1,6 GB pro Anfrage; er begrenzt den Durchsatz.
- Eigene Rechnung: Llama 3 70B braucht dank GQA bei 128K Kontext etwa 42,9 GB Cache statt rund 343,6 GB bei voller Kopfzahl.

https://kifachblatt.de/inferenz-und-kosten-verstehen

Quellen

1. Efficient Memory Management for Large Language Model Serving with PagedAttention (arxiv.org)
2. GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints (arxiv.org)
3. The Llama 3 Herd of Models (arxiv.org)
4. Neural Machine Translation of Rare Words with Subword Units (arxiv.org)
5. Pricing - Claude API Docs (docs.anthropic.com)

Vollständige Texte mit Quellen, Methode und Grenzen auf kifachblatt.de. „Eigene Rechnung“ kennzeichnet Berechnungen der Redaktion auf Basis der genannten Quellen.

Impressum & Redaktionsschluss

Anbieter nach § 5 DDG

Philipp Paulik
Mozartstraße 1
53819 Neunkirchen-Seelscheid
Nordrhein-Westfalen

Verantwortlich nach § 18 Abs. 2 MStV

Philipp Paulik, Anschrift wie links

Redaktion

KI Fachblatt, Redaktion Philipp Paulik

Kontakt

E-Mail: philipp.l.paulik@gmail.com
Web: kifachblatt.de

Redaktionsschluss

Diese Ausgabe wurde am 21.10.2026, 08:10 Uhr automatisch erstellt. Später veröffentlichte Beiträge und Zählerstände sind nicht berücksichtigt.

Hinweis zu KI

Die Inhalte des KI Fachblatts werden mit Unterstützung von KI erstellt und redaktionell geprüft (siehe kifachblatt.de/transparenz). Dieser Bericht wird automatisch aus öffentlichen Daten und den veröffentlichten Beiträgen zusammengestellt. Trotz Prüfung können Fehler nicht ausgeschlossen werden.

Datenquellen

Modellliste: Hugging Face, öffentliche API (huggingface.co/api/models, Sortierung trendingScore), Stand 21.10.2026, 08:10 Uhr. Analysen und KI-Verzeichnis: eigene Beiträge und Quellenprüfung des KI Fachblatts. Diagramme: eigene Darstellung der API-Zähler. Logos nur aus dem lokalen, quellengeprüften Bestand des KI Fachblatts (siehe Logos und Marken), sonst Kürzel; keine Profilbilder von Hugging Face.

Logos und Marken

Logos stammen aus dem lokalen Bestand des KI Fachblatts (content/portrait-logos), unverändert und eingebettet, mit Quelle und Rechtehinweis je Datei. Marken gehören ihren jeweiligen Inhabern. Die Logos dienen der redaktionellen Identifikation und deuten keine Partnerschaft, Freigabe oder Empfehlung durch die Markeninhaber an. Wo kein eindeutig zugeordnetes Logo vorliegt, steht ein Kürzel. Modelllogos und Unternehmenslogos werden nicht vermischt.

- **claude**: https://commons.wikimedia.org/wiki/File:Claude_AI_logo.svg · PD-textlogo laut Commons; Markenrechte bleiben bestehen
- **gemini**: https://commons.wikimedia.org/wiki/File:Google_Gemini_logo_2025.svg · PD-textlogo laut Commons; Markenrechte bleiben bestehen
- **google-deepmind**: https://commons.wikimedia.org/wiki/File:Google_DeepMind_logo.png · PD-textlogo laut Commons; Markenrechte bleiben bestehen
- **meta**: https://commons.wikimedia.org/wiki/File:Meta_Platforms_Inc._logo.svg · PD-textlogo laut Commons; Markenrechte bleiben bestehen
- **mistral-ai**: https://mistral.ai/brand/ · Offizielle Brand-Guidelines, keine freie Lizenz
- **mistral-large**: https://mistral.ai/brand/ · Offizielle Brand-Guidelines, keine freie Lizenz
- **mistral-small**: https://mistral.ai/brand/ · Offizielle Brand-Guidelines, keine freie Lizenz
- **nvidia**: https://commons.wikimedia.org/wiki/File:NVIDIA_logo.svg · Apache-2.0; Copyright NVIDIA Corporation. Lizenzdatei beigelegt.
- **openai**: https://openai.com/brand/ · Offizielle Brand-Guidelines, keine freie Lizenz

© 2026 KI Fachblatt · Philipp Paulik · Stand 21.10.2026, 08:10 Uhr