KI Fachblatt

KI-Tagesbericht

Dienstag, 20.10.2026 · Trending-Modelle und die Analysen des Tages

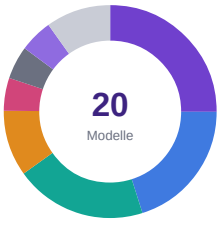
MODELLE IM RANKING	DOWNLOADS GESAMT	HÖCHSTER TREND-SCORE	JÜNGSTES MODELL
20	**16,4 Mio.**	**1.622**	**vor 3 Tg.**
Top-Auswahl der HF-API	Zähler der API, kein Qualitätsmaß	DeepSeek-V4.1-Flash-1017	DeepSeek-V4.1-Flash-1017

Trend-Ranking

Top 10 nach Trend-Score · Stand 20.10.2026, 12:10 Uhr

1	DE	**DeepSeek-V4.1-Flash-1017** deepseek-ai · Bild+Text zu Text	1.622
2	BL	**flux-3-image-klein-comfy** black-forest-labs · Bild zu Bild	785
3	FI	**drama-3** fishaudio · Sprachsynthese	758
4	Google DeepMind	**embeddinggemma-2** google · Embeddings	572
5	JI	**humanizer** jialinyyzz · Textgenerierung	561
6	Meta	**Muse-Spark-Open-816B-A42B** meta-models · Bild+Text zu Text	543
7	LI	**LFM2.5-24B-A2B** LiquidAI · Textgenerierung	489
8	BL	**flux-3-image-klein** black-forest-labs · Bild zu Bild	489
9	OP	**MOSS-Image-SFT** OpenMOSS-Team · Text zu Bild	437
10	LI	**LTX-2.5** Lightricks · Bild zu Video	435

Aufgaben im Ranking



Bild+Text zu Text	5
Textgenerierung	4
Text zu Bild	4
Bild zu Bild	2
Sprachsynthese	1
Embeddings	1
Bild zu Video	1
Weitere	2

Alter der Modelle



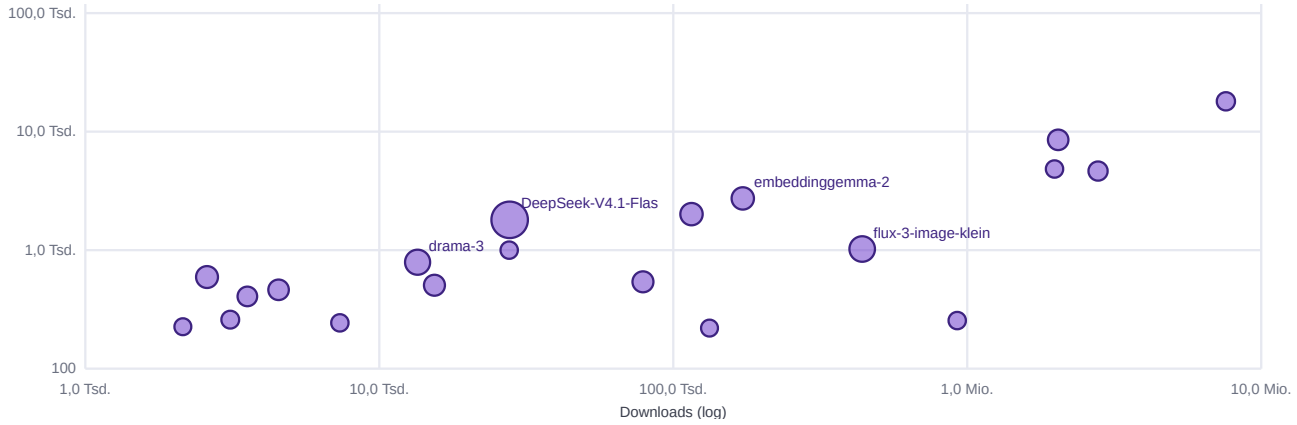
bis 7 Tage	5
8 bis 30 Tage	9
31 bis 180 Tage	6
älter	0

Wer vorn liegt

BL	black-forest-labs	2
LI	LiquidAI	2
OP	OpenMOSS-Team	2
QW	Qwen	2
DE	deepseek-ai	1

Beachtung und Nutzung

Likes gegen Downloads, logarithmisch



Jeder Punkt ist ein Modell, die Größe zeigt den Trend-Score. Hohe Downloads bei wenigen Likes und umgekehrt sind normal und sagen nichts über Qualität.

Alle 20 Modelle

Top 20 laut Hugging-Face-API · Stand 20.10.2026, 12:10 Uhr

#	MODELL	AUFGABE	LIKES	DOWNLOADS	TREND-SCORE	ERSTELLT
1	DeepSeek-V4.1-Flash-1017 deepseek-ai	Bild+Text zu Text	1.802	27.737	1.622	2026-10-17
2	flux-3-image-klein-comfy black-forest-labs	Bild zu Bild	1.023	439.528	785	2026-10-14
3	drama-3 fishaudio	Sprachsynthese	791	13.495	758	2026-10-01
4	embeddinggemma-2 google	Embeddings	2.736	172.474	572	2026-09-14
5	humanizer jialinyyzz	Textgenerierung	2.009	115.341	561	2026-09-11
6	Muse-Spark-Open-816B-A42B meta-models	Bild+Text zu Text	592	2.592	543	2026-09-15
7	LFM2.5-24B-A2B LiquidAI	Textgenerierung	505	15.410	489	2026-10-12
8	flux-3-image-klein black-forest-labs	Bild zu Bild	540	78.897	489	2026-10-13
9	MOSS-Image-SFT OpenMOSS-Team	Text zu Bild	463	4.547	437	2026-10-11
10	LTX-2.5 Lightricks	Bild zu Video	8.530	2.039.447	435	2026-07-23
11	MOSS-Image-Base OpenMOSS-Team	Text zu Bild	407	3.558	385	2026-10-11
12	Qwen-Image-2.1-Uncensored-Quantized abenzerps	Text zu Bild	4.658	2.788.283	354	2026-09-20
13	Qwen3.8-27B Qwen	Bild+Text zu Text	18.030	7.586.857	287	2026-08-05
14	indra-ocr datalab-to	Bild zu Text	259	3.111	255	2026-10-10
15	MOSS-Image Comfy-Org	Ohne Angabe	255	924.574	249	2026-10-16
16	Qwen3.8-Flash-Next-FP4-Local nvidia	Bild+Text zu Text	244	7.345	240	2026-10-08
17	Unlimited-OCR baidu	Bild+Text zu Text	4.830	1.981.704	228	2026-06-19
18	Qwen-Image-2.1-Turbo Qwen	Text zu Bild	1.001	27.652	226	2026-10-09
19	Hy-Memory-30B-A3B tencent	Textgenerierung	226	2.145	223	2026-10-15
20	LFM2.5-24B-A2B-GGUF LiquidAI	Textgenerierung	220	132.848	214	2026-10-09

So lesen: Reihenfolge nach dem Feld *trendingScore* der Hugging-Face-API, Stand 20.10.2026, 12:10 Uhr. Likes, Downloads und Trend-Score sind Zähler der API, keine Qualitätsbewertung und kein Benchmark-Ergebnis. Die Diagramme zeigen nur diese Zähler.

Aus dem KI-Verzeichnis

Modelle mit Quellen auf kifachblatt.de/ki-modelle

GPT-6 Astra

OpenAI

GPT-6 Astra ist ein OpenAI-Modell für komplexes Reasoning, Programmieren, Recherche und Dokumentarbeit.

Ein Text Bild → Aus Text

Claude Opus 5

Anthropic

Claude-Modell für komplexe Programmier- und Unternehmensaufgaben.

Ein Text Bild → Aus Text

Claude Sonnet 5

Anthropic

Claude-Modell, das laut Anbieter Geschwindigkeit und Leistungsfähigkeit verbindet.

Ein Text Bild → Aus Text

Gemini 4 Argon

Google DeepMind

Multimodales Reasoning-Modell für komplexe technische und berufliche Aufgaben.

Ein Text Bild Audio Video → Aus Text

13. Oktober 2026

Mistral Small 4

Mistral AI

Ein hybrides Modell für Anweisungen, Reasoning und Programmieren.

16. März 2026

Mistral Large 3

Mistral AI

Ein multimodales Open-Weight-Modell mit Mixture-of-Experts-Architektur.

2. Dezember 2025

Nemotron 3.5 Super VL NVFP4

NVIDIA

Ein Modell für Text, Bilder und Video mit quantisierten Gewichten.

Ein Text Bild Video → Aus Text

15. Oktober 2026

Muse Spark

Meta

Multimodales Reasoning-Modell, das Meta AI antreibt.

8. April 2026

Benchmark-Angaben der Hersteller

GPQA Diamond · Nemotron 3.5 Super VL NVFP4

89,90 %



Herstellertabelle, laut NVIDIA

SWE-bench Verified Verified · Nemotron 3.5 Super VL NVFP4

71,07 %



Herstellertabelle, laut NVIDIA

Terminal-Bench 2.1 2.1 · Nemotron 3.5 Super VL NVFP4

60,80 %



Herstellertabelle, laut NVIDIA

SWE-bench Verified Verified · MiniMax-M2.1

74,00 %



Herstellertabelle, laut MiniMax

MMLU-Pro - · MiniMax-M2.1

88,00 %



Herstellertabelle, laut MiniMax

GPQA Diamond · MiniMax-M2.1

83,00 %



Herstellertabelle, laut MiniMax

SWE-bench Verified Verified · MiniMax-M2.5

80,20 %

Herstellertabelle, laut MiniMax

Einordnen: Diese Werte sind Herstellerangaben aus einer Modellkarte. Setup, Prompt und Budget sind nicht vollständig angegeben, die Zahlen eignen sich nicht für Ranglisten oder den Vergleich zwischen Modellen.

Quellen und Prüfdatum (2026-10-20) je Eintrag unter kifachblatt.de/ki-modelle und kifachblatt.de/benchmarks.

Die zwei Analysen des Tages

GRUNDLAGEN · 20.10.2026 · 5 QUELLEN

Inferenz und Kosten verstehen: Tokens, KV-Cache, Quantisierung

Was beim Antworten passiert, warum der KV-Cache so viel Speicher frisst und woraus sich ein API-Preis ergibt, mit eigenen Rechnungen zu Llama 3.

- Ein Modell antwortet in zwei Phasen: Die Eingabe wird parallel verarbeitet, die Ausgabe Token für Token; die zweite Phase ist speicherlastig.
- Der KV-Cache kostet beim 13-Milliarden-Modell OPT 800 KB pro Token und bis zu 1,6 GB pro Anfrage; er begrenzt den Durchsatz.
- Eigene Rechnung: Llama 3 70B braucht dank GQA bei 128K Kontext etwa 42,9 GB Cache statt rund 343,6 GB bei voller Kopfzahl.

https://kifachblatt.de/inferenz-und-kosten-verstehen

Quellen

1. Efficient Memory Management for Large Language Model Serving with PagedAttention (arxiv.org)
2. GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints (arxiv.org)
3. The Llama 3 Herd of Models (arxiv.org)
4. Neural Machine Translation of Rare Words with Subword Units (arxiv.org)
5. Pricing - Claude API Docs (docs.anthropic.com)

GRUNDLAGEN · 20.10.2026 · 8 QUELLEN

Wie ein Sprachmodell lernt: von Pretraining bis RLVR

Pretraining, SFT, RLHF, DPO und RLVR einfach erklärt: Was jede Stufe leistet, warum Modelle so verschieden wirken und was die Begriffe in Modellkarten bedeuten.

- Ein Sprachmodell lernt in Stufen: Pretraining (Nächstes-Token-Vorhersage), SFT (Musterantworten), Präferenzlernen (RLHF, DPO) und RLVR (automatisch prüfbare Aufgaben).
- Llama 3 405B wurde mit 15,6 Billionen Token und 3,8 × 10^{25} Rechenoperationen vortrainiert, rund 38,5 Token pro Parameter (eigene Rechnung).
- Nach dem Chinchilla-Ergebnis sollten Modellgröße und Datenmenge gemeinsam wachsen; ein 70-Milliarden-Modell mit mehr Daten schlug ein 280-Milliarden-Modell.

https://kifachblatt.de/wie-ein-sprachmodell-lernt

Quellen

1. Scaling Laws for Neural Language Models (arxiv.org)
2. Training Compute-Optimal Large Language Models (arxiv.org)
3. The Llama 3 Herd of Models (arxiv.org)
4. Training language models to follow instructions with human feedback (arxiv.org)
5. Direct Preference Optimization: Your Language Model is Secretly a Reward Model (arxiv.org)
6. Tulu 3: Pushing Frontiers in Open Language Model Post-Training (arxiv.org)
7. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models (arxiv.org)
8. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning (arxiv.org)

Vollständige Texte mit Quellen, Methode und Grenzen auf kifachblatt.de. „Eigene Rechnung“ kennzeichnet Berechnungen der Redaktion auf Basis der genannten Quellen.

Impressum & Redaktionsschluss

Anbieter nach § 5 DDG

Philipp Paulik
Mozartstraße 1
53819 Neunkirchen-Seelscheid
Nordrhein-Westfalen

Verantwortlich nach § 18 Abs. 2 MStV

Philipp Paulik, Anschrift wie links

Redaktion

KI Fachblatt, Redaktion Philipp Paulik

Kontakt

E-Mail: philipp.l.paulik@gmail.com
Web: kifachblatt.de

Redaktionsschluss

Diese Ausgabe wurde am 20.10.2026, 12:10 Uhr automatisch erstellt. Später veröffentlichte Beiträge und Zählerstände sind nicht berücksichtigt.

Hinweis zu KI

Die Inhalte des KI Fachblatts werden mit Unterstützung von KI erstellt und redaktionell geprüft (siehe kifachblatt.de/transparenz). Dieser Bericht wird automatisch aus öffentlichen Daten und den veröffentlichten Beiträgen zusammengestellt. Trotz Prüfung können Fehler nicht ausgeschlossen werden.

Datenquellen

Modellliste: Hugging Face, öffentliche API (huggingface.co/api/models, Sortierung trendingScore), Stand 20.10.2026, 12:10 Uhr. Analysen und KI-Verzeichnis: eigene Beiträge und Quellenprüfung des KI Fachblatts. Diagramme: eigene Darstellung der API-Zähler. Logos nur aus dem lokalen, quellengeprüften Bestand des KI Fachblatts (siehe Logos und Marken), sonst Kürzel; keine Profilbilder von Hugging Face.

Logos und Marken

Logos stammen aus dem lokalen Bestand des KI Fachblatts (content/portrait-logos), unverändert und eingebettet, mit Quelle und Rechtehinweis je Datei. Marken gehören ihren jeweiligen Inhabern. Die Logos dienen der redaktionellen Identifikation und deuten keine Partnerschaft, Freigabe oder Empfehlung durch die Markeninhaber an. Wo kein eindeutig zugeordnetes Logo vorliegt, steht ein Kürzel. Modelllogos und Unternehmenslogos werden nicht vermischt.

- **claude**: https://commons.wikimedia.org/wiki/File:Claude_AI_logo.svg · PD-textlogo laut Commons; Markenrechte bleiben bestehen
- **gemini**: https://commons.wikimedia.org/wiki/File:Google_Gemini_logo_2025.svg · PD-textlogo laut Commons; Markenrechte bleiben bestehen
- **google-deepmind**: https://commons.wikimedia.org/wiki/File:Google_DeepMind_logo.png · PD-textlogo laut Commons; Markenrechte bleiben bestehen
- **meta**: https://commons.wikimedia.org/wiki/File:Meta_Platforms_Inc._logo.svg · PD-textlogo laut Commons; Markenrechte bleiben bestehen
- **mistral-large**: https://mistral.ai/brand/ · Offizielle Brand-Guidelines, keine freie Lizenz
- **mistral-small**: https://mistral.ai/brand/ · Offizielle Brand-Guidelines, keine freie Lizenz
- **nvidia**: https://commons.wikimedia.org/wiki/File:NVIDIA_logo.svg · Apache-2.0; Copyright NVIDIA Corporation. Lizenzdatei beigelegt.
- **openai**: https://openai.com/brand/ · Offizielle Brand-Guidelines, keine freie Lizenz

© 2026 KI Fachblatt · Philipp Paulik · Stand 20.10.2026, 12:10 Uhr