KI Fachblatt

KI-Tagesbericht

Montag, 19.10.2026 · Trending-Modelle und die Analysen des Tages

Trending-Modelle

Top 20 laut Hugging-Face-API · Stand 19.10.2026, 10:55 Uhr

#	MODELL	AUFGABE	LIKES	DOWNLOADS	TREND-SCORE	ERSTELLT
1	deepseek-ai/DeepSeek-V4.1-Flash-1017	image-text-to-text	1.528	17.924	1.403	2026-10-17
2	openbmb/MiniCPM-V-4.7-35B-A3B	image-text-to-text	1.029	76.410	843	2026-10-07
3	fishaudio/drama-3	text-to-speech	725	11.795	698	2026-10-01
4	google/embeddinggemma-2	feature-extraction	2.686	167.750	693	2026-09-14
5	black-forest-labs/flux-3-image-klein-comfy	image-to-image	869	393.062	681	2026-10-14
6	jialinyyzz/humanizer	text-generation	1.967	109.937	647	2026-09-11
7	meta-models/Muse-Spark-Open-816B-A42B	image-text-to-text	566	2.109	521	2026-09-15
8	black-forest-labs/flux-3-image-klein	image-to-image	509	62.006	467	2026-10-13
9	LiquidAI/LFM2.5-24B-A2B	text-generation	481	14.151	465	2026-10-12
10	Lightricks/LTX-2.5	image-to-video	8.420	2.019.834	456	2026-07-23
11	abenzerps/Qwen-Image-2.1-Uncensored-Quantized	text-to-image	4.592	2.739.572	389	2026-09-20
12	OpenMOSS-Team/MOSS-Image-SFT	text-to-image	373	3.336	358	2026-10-11
13	OpenMOSS-Team/MOSS-Image-Base	text-to-image	335	2.774	322	2026-10-11
14	baidu/Unlimited-OCR	image-text-to-text	4.809	1.799.825	298	2026-06-19
15	openbmb/MiniCPM-V-4.7-1B	image-text-to-text	390	33.388	296	2026-10-06
16	Qwen/Qwen3.8-27B	image-text-to-text	17.980	7.458.401	292	2026-08-05
17	Qwen/Qwen-Image-2.1-Turbo	text-to-image	988	25.033	286	2026-10-09
18	nvidia/Qwen3.8-Flash-Next-FP4-Local	image-text-to-text	224	6.047	221	2026-10-08
19	datalab-to/indra-ocr	image-to-text	216	2.433	212	2026-10-10
20	facebook/sam3	mask-generation	4.652	1.902.371	208	2025-11-07

So lesen: Reihenfolge nach dem Feld *trendingScore* der Hugging-Face-API, Stand 19.10.2026, 10:55 Uhr. Likes, Downloads und Trend-Score sind Zähler der API, keine Qualitätsbewertung und kein Benchmark-Ergebnis. „Aufgabe“ ist das Feld *pipeline_tag*. Quelle: huggingface.co (öffentliche API, ohne Schlüssel).

Die zwei Analysen des Tages

MODELLE · 19.10.2026 · 8 QUELLEN

Nemotron 3.5: Was 99,62 Prozent Quantisierungserhalt bedeuten

NVIDIAs offene Modelle Super und Lightning im Check: Destillation, NVFP4 gegen BF16 in 36 Benchmark-Zeilen und die Frage, was ein Median verbirgt.

- Super: 120 Mrd. Parameter, 12 Mrd. aktiv (10 %), 1 Mio. Token Kontext; Lightning: 30 Mrd., 3 Mrd. aktiv; Veröffentlichung 14./15. Oktober 2026.
- NVFP4 erreicht in 36 Zeilen der Modellkarte im Median 99,44 Prozent des BF16-Werts (NVIDIA: 99,62 Prozent); in 30 von 36 Zeilen liegt die Abweichung bei höchstens einem Punkt (eigene Rechnung).
- Vier Zeilen liegen unter 95 Prozent, darunter DeepSWE (offline) mit 73,8 Prozent und WebVoyager (offline) mit 85,3 Prozent; die Karte nennt keine Streuung.

https://kifachblatt.de/nemotron-3-5-super-lightning-analyse

Quellen

1. NVIDIA Nemotron 3.5 Super and Lightning (Zusammenfassung des Technical Reports) (research.nvidia.com)
2. NVIDIA-Nemotron-3.5-Super-VL-120B-A12B-NVFP4 (Modellkarte) (huggingface.co)
3. NVIDIA-Nemotron-3.5-Super-VL-120B-A12B-NVFP4-LiLiCorr (Modellkarte) (huggingface.co)
4. NVIDIA-Nemotron-3.5-Super-VL-120B-A12B released, with Spark-dedicated vLLM config + LiLiCorr speculative decoding model (Forumsthread, Nutzerbeiträge) (forums.developer.nvidia.com)
5. Fast Inference from Transformers via Speculative Decoding (arxiv.org)
6. Better & Faster Large Language Models via Multi-token Prediction (arxiv.org)
7. Distilling the Knowledge in a Neural Network (arxiv.org)
8. Mamba: Linear-Time Sequence Modeling with Selective State Spaces (arxiv.org)

MODELLE · 19.10.2026 · 9 QUELLEN

Beam 501B: Reflections offenes Modell im Nachrechnen

Reflections erstes offenes Modell im Check: Parameterbilanz, KV-Cache, Quantisierung und Benchmarks, nachgerechnet und von Herstellerangaben getrennt.

- 501,3 Mrd. Parameter, 23,4 Mrd. aktiv, 1 Mio. Token Kontext, Apache 2.0; veröffentlicht am 16. Oktober 2026.
- Die Parameterangaben lassen sich nachrechnen: 49 × 256 Experten à 39,3 Mio. ergeben 98,4 Prozent der Parameter und 23,46 Mrd. aktive.
- Dank 43 lokaler und 9 globaler Attention-Schichten wächst der KV-Cache auf 36 GiB bei einer Million Token statt auf 208 GiB (eigene Rechnung, deckt sich mit dem Blog).

https://kifachblatt.de/beam-501b-reflection-offenes-modell-analyse

Quellen

1. Introducing Beam: Reflection's 501B open-weight model (reflection.ai)
2. Beam is now available (reflection.ai)
3. Welcome Beam: a 501B open model you can own, customize, and scale (huggingface.co)
4. reflection/Beam-1.0-501B-A23B (Modellkarte) (huggingface.co)
5. Beam Safety Technical Report (reflection.ai)
6. DeepSeek-V3 Technical Report (arxiv.org)
7. Scalable-Softmax Is Superior for Attention (arxiv.org)
8. Auxiliary-Loss-Free Load Balancing Strategy for Mixture-of-Experts (arxiv.org)
9. Deliberative Alignment: Reasoning Enables Safer Language Models (arxiv.org)

Vollständige Texte mit Quellen, Methode und Grenzen auf kifachblatt.de. „Eigene Rechnung“ kennzeichnet Berechnungen der Redaktion auf Basis der genannten Quellen.

Impressum & Redaktionsschluss

Anbieter nach § 5 DDG

Philipp Paulik
Mozartstraße 1
53819 Neunkirchen-Seelscheid
Nordrhein-Westfalen

Verantwortlich nach § 18 Abs. 2 MStV

Philipp Paulik, Anschrift wie links

Redaktion

KI Fachblatt, Redaktion Philipp Paulik

Kontakt

E-Mail: philipp.l.paulik@gmail.com
Web: kifachblatt.de

Redaktionsschluss

Diese Ausgabe wurde am 19.10.2026, 10:55 Uhr automatisch erstellt. Später veröffentlichte Beiträge und Zählerstände sind nicht berücksichtigt.

Hinweis zu KI

Die Inhalte des KI Fachblatts werden mit Unterstützung von KI erstellt und redaktionell geprüft (siehe kifachblatt.de/transparenz). Dieser Bericht wird automatisch aus öffentlichen Daten und den veröffentlichten Beiträgen zusammengestellt. Trotz Prüfung können Fehler nicht ausgeschlossen werden.

Datenquellen

Modellliste: Hugging Face, öffentliche API (huggingface.co/api/models, Sortierung trendingScore), Stand 19.10.2026, 10:55 Uhr. Analysen: eigene Beiträge des KI Fachblatts.

© 2026 KI Fachblatt · Philipp Paulik · Stand 19.10.2026, 10:55 Uhr