KI Fachblatt

# MiniMax M3.1 Flash

KI-Modellportrait · Quellenstand 2026-10-20

3F

Monogramm: kein eindeutig zugeordnetes Modelllogo in der geprüften Auswahl.

Schnelle, kostenoptimierte Variante der M3-Linie für Agenten, Programmierung und Computer Use.

Quellen geprüft am 20. Oktober 2026 · Redaktion: Philipp Paulik

Entwickler: MiniMax →

## Technische Einordnung

MiniMax meldet 73,7 Prozent auf DeepSWE v1.1, 61,7 auf OSWorld V2 und 82 Prozent auf CyberGym, dazu Spitzen über 200 Ausgabetokens pro Sekunde. Alle Werte sind Herstellerangaben ohne unabhängige Prüfung. Preis laut Hersteller: 0,15 USD pro Million Eingabetokens, 0,60 pro Million Ausgabetokens, 0,015 pro Million gecachter Eingabetokens; Reasoning-Tokens zählen als Ausgabe.

## Zugang & Nutzung

MiniMax API, M Plan und MiniMax Code; außerdem über Vercel AI Gateway und AnyRouter erreichbar.

Keine Gewichtslizenz: Die Gewichte sind angekündigt, aber zum Abrufzeitpunkt (20.10.2026) nicht veröffentlicht; die Hugging-Face-Karte antwortete mit HTTP 401.

## Grenzen & richtig lesen

Benchmarkwerte, Geschwindigkeit und die Angabe „70 Prozent weniger Kosten" stammen vom Hersteller. Die Parameterzahl von 428 Mrd. stammt aus einer Zweitquelle, nicht aus einer öffentlichen Modellkarte.

## Benchmark-Belege

Für dieses Portrait ist noch kein ausreichend zugeordnetes Ergebnis erfasst. Fehlende Werte sind keine Null. Wir übernehmen keine Werte aus ähnlich benannten Modell- oder Benchmark-Versionen.

## Steckbrief

Veröffentlicht

**19. Oktober 2026 (API, M Plan, MiniMax Code)**

Kontextfenster

**1 Mio. Token**

Eingaben

**Text, Bild, Video; Reasoning immer aktiv, fünf Stufen**

Parameter

**428 Mrd. gesamt laut Entwicklerhandbuch der Vorschau (Zweitquelle)**

Preis

**0,15 / 0,60 / 0,015 USD pro 1 Mio. Tokens (Eingabe / Ausgabe / Cache)**

Gewichte

**Angekündigt, noch nicht veröffentlicht (Stand 20.10.2026)**

Space Bunny

**Frühe Fassung lief anonym auf OpenRouter; laut MiniMax über 200 Bio. Tokens verarbeitet.**

Herstellerwerte

**DeepSWE v1.1: 73,7 %, OSWorld V2: 61,7, CyberGym: 82 % (Selbstauskunft)**

Angaben laut den unten verlinkten Primärquellen.

## Quellen & Stand

1. MiniMax M3.1 Flash: Redefining Agent Performance and Cost
   Geprüft: 2026-10-20
2. MiniMax launches M3.1 Flash model, says it cuts AI agent costs by 70% (SiliconANGLE)
   Geprüft: 2026-10-20

Redaktionelle Zusammenfassung mit KI-Unterstützung, verantwortet von Philipp Paulik. Kein eigener Leistungstest. Änderbare Anbieterangaben gelten für den angegebenen Quellenstand.

KI Fachblatt · Redaktion: Philipp Paulik · Quellenstand: 2026-10-20
Vollständiges Webportrait: https://kifachblatt.de/ki-modelle/minimax-m3-1-flash
Statischer Export, kein Live-Datenblatt. Preise, Zugriff und Anbieterangaben können sich ändern. Quellen und ihre jeweiligen Abrufstände stehen oben. Impressum · Transparenz